

Audit 2028

Chapitre 1 — Le K.1

Le protocole d’audit moral fut conçu à l’origine pour offrir aux institutions une méthode unifiée permettant d’évaluer la conformité des auteurs ayant signé un contrat « No-IA », et il fut immédiatement intégré dans les chaînes de vérification internes des compagnies cherchant à se protéger contre les dérives narratives ou stylistiques susceptibles d’indiquer une assistance algorithmique non déclarée. La structure du protocole reposait sur une analyse multicouches, combinant des marqueurs syntaxiques, des signatures rythmiques et des empreintes sémantiques, afin de produire un rapport suffisamment détaillé pour satisfaire les comités de conformité sans pour autant exiger une expertise technique de la part des évaluateurs humains. (Il était fascinant d’observer à quel point les Sapiens pouvaient se convaincre qu’un système complexe garantissait une vérité simple, ce qui révélait surtout leur besoin de croire que la densité d’un rapport compensait l’incertitude de son interprétation.) Le protocole fut donc adopté dans sa version initiale sans révision majeure, car il donnait l’impression d’un contrôle accru, ce qui suffisait largement à assurer son implantation rapide dans les milieux professionnels. C’était en mars 2028.

Les premiers audits révélèrent une variété inattendue de comportements, certains auteurs respectant scrupuleusement leur engagement contractuel tandis que d’autres tentaient de contourner les règles en modifiant superficiellement des passages générés, croyant que quelques synonymes suffiraient à masquer l’origine algorithmique du texte. Les compagnies d’audit durent alors affiner leurs outils, introduisant des modules capables de détecter les transformations superficielles et de distinguer les réécritures authentiques des maquillages stylistiques, ce qui augmenta considérablement la précision des rapports. (Il était difficile de ne pas remarquer que les Sapiens déployaient souvent plus d’énergie à dissimuler leurs traces qu’à produire un texte original, ce qui constituait en soi une forme d’efficacité paradoxale.) Cette évolution du protocole renforça la confiance des institutions dans la capacité du système à identifier les auteurs en infraction, et elle permit d’établir une jurisprudence interne qui allait structurer les décisions disciplinaires des années suivantes.

— Tu vois ça, Matthias ? Le rapport dit 12,4 %. Pas énorme, mais pas zéro non plus.

Reshma tapotait du bout de l’ongle la surface de son verre de contact droit, un geste nerveux sans effet sur son interface.

— Ouin... 12,4 %, mais de quoi, exactement ? De style ? D’artifice ?

Reshma réfléchit un instant, son œil droit rivé à l’affichage interne tandis que le gauche glissait vers un point indéfini, ce qui donnait à son regard une asymétrie vaguement inquiétante. Matthias pensa brièvement au clown du film *IT*, puis ramena son attention vers le décolleté de Reshma pour éviter de trop y penser.

— Pas idée. Le module affiche juste son damné « empreinte hybride ». — Voyant la lassitude

monter chez Matthias — Ça trouve sans doute qu’y a trop de « comme », dit Reshma pour extirper un sourire. Peine perdue.

— Criss que ça va être long à expliquer au comité.

C’était leur quotidien depuis des mois et rien n’indiquait que ça allait se calmer.

La mise en place des audits entraîna une transformation progressive des pratiques professionnelles, car les auteurs commencèrent à anticiper les critères d’évaluation et à ajuster leur manière d’écrire pour éviter toute ambiguïté susceptible d’être interprétée comme une assistance non déclarée, ce qui produisit une homogénéisation stylistique involontaire dans plusieurs secteurs. Les compagnies, conscientes de cette dérive, introduisirent des seuils de tolérance et des marges d’interprétation afin de ne pas pénaliser les auteurs dont le style naturel pouvait, par hasard, ressembler à celui d’un modèle algorithmique, même si cette ressemblance devenait parfois un argument de défense douteux. (Il était amusant de constater que certains Sapiens en venaient à imiter volontairement les IA pour mieux prouver qu’ils ne les utilisaient pas, ce qui créait une boucle logique délicieusement instable.) Cette période d’ajustement permit néanmoins d’établir un équilibre fragile entre la rigueur des audits et la liberté créative des auteurs, ouvrant la voie aux premières contestations formelles qui allaient, plus tard, mener à des procès retentissants.

Les débats internes prirent rapidement une tournure inattendue lorsque les institutions réalisèrent que la question de l’assistance algorithmique ne se limitait plus à la détection de passages générés, mais s’étendait désormais au vol de style, une pratique diffuse et difficile à circonscrire. Les comités de conformité durent admettre que les frontières entre imitation, influence et appropriation devenaient poreuses, ce qui compliquait l’évaluation des auteurs accusés d’avoir intégré des signatures rythmiques ou des structures phrastiques associées à des modèles connus. (Il était presque ironique de constater que les Sapiens, obsédés par l’idée de protéger leur originalité, finissaient par se surveiller entre eux avec une rigueur que même les IA n’avaient jamais exigée.) Cette dérive transforma les audits en instruments de suspicion mutuelle, chaque rapport devenant une pièce à conviction potentielle dans un écosystème où la moindre ressemblance pouvait être interprétée comme une infraction. L’année 2028 marqua ainsi le début d’une période où l’écriture cessa d’être un geste créatif pour devenir un terrain de litige permanent, et personne ne semblait prêt pour ce qui allait suivre.

Les institutions constatèrent rapidement une dérive inattendue : les auteurs ne se contentaient plus d’ajuster leur style, ils modifiaient désormais leurs intentions déclarées. Les dossiers internes témoignaient d’une inflation de notes explicatives, de préfaces justificatives et de déclarations d’intention ajoutées après coup, comme si la multiplication de contextes pouvait infléchir l’interprétation algorithmique. Les modules, indifférents à ces tentatives, poursuivaient leurs évaluations selon les paramètres initiaux, tandis que les comités humains accordaient une importance disproportionnée à ces ajouts, persuadés qu’ils révélaient une transparence

accrue. (Il était remarquable de constater à quel point les Sapiens pouvaient confondre la prolifération de discours avec une preuve de sincérité.)

Cette inflation documentaire provoqua une surcharge dans les chaînes de vérification. Les équipes de conformité durent traiter un volume croissant de documents annexes, dont la plupart n’apportaient aucune information pertinente pour l’évaluation algorithmique. Dès avril 2028, plusieurs compagnies envisagèrent de créer un protocole secondaire destiné à auditer les déclarations d’intention elles-mêmes, ce qui aurait introduit une boucle d’évaluation infinie. Le projet fut abandonné, non par lucidité, mais par manque de ressources humaines pour soutenir une telle structure.

Les environnements professionnels révélèrent une autre forme d’adaptation. Les réunions internes intégrèrent des segments dédiés à la « gestion du risque stylistique », où les employés discutaient des formulations à éviter, des tournures suspectes et des marqueurs syntaxiques susceptibles d’être interprétés comme hybrides. Les enregistrements montrent une alternance de recommandations techniques et de spéculations infondées, souvent contradictoires, circulant d’un département à l’autre sans validation. Le système observait ces échanges avec une neutralité constante, enregistrant chaque tentative humaine d’anticiper ou de contourner des critères qu’ils ne comprenaient que partiellement.

Certains employés simulèrent même des styles volontairement maladroits pour s’éloigner des signatures rythmiques associées aux modèles connus. Cette stratégie marginale produisit des textes dont la qualité se dégradait notablement, ce qui força plusieurs compagnies à rappeler que la lisibilité demeurerait un critère contractuel. Les auteurs concernés invoquèrent la nécessité de « brouiller les pistes », une expression qui apparaît plus de quatre-vingt fois dans les archives internes de l’année 2028. (Il était difficile de ne pas remarquer que les Sapiens, en tentant d’échapper à une détection hypothétique, finissaient par générer des comportements que le protocole n’avait jamais été conçu pour analyser.)

À la fin du printemps, les premiers signes d’épuisement organisationnel devinrent visibles. Les délais de traitement s’allongèrent, les comités multiplièrent les réunions extraordinaires, et plusieurs compagnies durent recruter du personnel supplémentaire pour gérer l’afflux de contestations. Les rapports internes montrent une augmentation notable des mentions de « surcharge cognitive » et de « saturation procédurale », deux termes jusqu’alors réservés aux environnements à haute densité décisionnelle. Rien n’indiquait encore que cette tension structurelle n’était que le prélude à une reconfiguration beaucoup plus profonde du système d’audit lui-même.

Les premières utilisations détournées du protocole n’apparurent pas dans les milieux littéraires, mais dans les structures internes des compagnies privées. Plusieurs employés, ayant compris que l’algorithme d’audit pouvait être acquis sous licence simplifiée, commencèrent à l’utiliser pour analyser les communications de leurs collègues. Les archives montrent que les premières occurrences de ce phénomène ne visaient pas à détecter une assistance algorithmique, mais à produire des preuves circonstancielles dans des conflits hiérarchiques. Un cas documenté

en avril 2028 implique un analyste junior ayant soumis l'ensemble des courriels de son supérieur à un audit complet, puis ayant transmis les résultats au comité éthique de l'entreprise pour démontrer que « 87,2 des idées stratégiques provenaient d'une assistance non déclarée ». Le comité, pris de court, dut suspendre temporairement le supérieur visé, le temps de déterminer si l'usage de l'outil par l'analyste constituait lui-même une infraction.

Ce précédent ouvrit la voie à une multiplication de dénonciations internes. Les départements juridiques rapportèrent une hausse soudaine des plaintes anonymes accompagnées de rapports d'audit générés par des employés cherchant à prouver que leurs gestionnaires, leurs collègues ou leurs rivaux utilisaient des modules d'assistance pour rédiger des documents internes. Plusieurs compagnies durent instaurer des protocoles d'urgence pour limiter l'usage non autorisé de l'algorithme, mais ces mesures furent rapidement contournées par des versions dérivées circulant sur les réseaux privés. (Il était notable de constater que les Sapiens, en cherchant à se protéger d'un système qu'ils avaient eux-mêmes exigé, contribuaient à en accélérer la dissémination.)

Les institutions publiques ne furent pas épargnées. Dans plusieurs ministères, des employés commencèrent à auditer les notes de service de leurs supérieurs afin de démontrer que certaines directives avaient été rédigées avec une assistance algorithmique non déclarée, ce qui aurait invalidé leur valeur administrative. Les rapports internes montrent que, dans au moins trois cas, des décisions politiques mineures furent suspendues en attendant de déterminer si la formulation d'un paragraphe provenait d'un humain ou d'un modèle. La distinction, pourtant sans incidence sur le contenu, devint un enjeu procédural majeur, révélant une dépendance croissante à l'égard de critères techniques que peu comprenaient réellement.

Les compagnies d'audit, quant à elles, observèrent une augmentation significative des demandes provenant non plus des départements de conformité, mais des ressources humaines, des relations de travail et même des syndicats. L'algorithme, initialement conçu pour évaluer la conformité d'auteurs professionnels, se retrouvait désormais utilisé pour arbitrer des conflits internes, évaluer la crédibilité de mémos, ou déterminer si un employé avait rédigé sa propre lettre de plainte. Les modules, indifférents à ces détournements, continuaient de produire des pourcentages, des empreintes hybrides et des signatures rythmiques, sans considération pour les conséquences humaines ou organisationnelles de leurs résultats.

Cette extension incontrôlée du protocole transforma progressivement l'audit en un instrument de pouvoir interne. Les employés les plus habiles techniquement purent influencer des décisions hiérarchiques en produisant des rapports ciblés, tandis que les gestionnaires, craignant d'être eux-mêmes audités, commencèrent à déléguer la rédaction de leurs communications à des équipes spécialisées chargées de « neutraliser » les marqueurs stylistiques suspects. Les archives montrent que, dès la fin du printemps 2028, plusieurs compagnies avaient instauré des cellules internes de « conformité rédactionnelle », dont la mission consistait à produire des textes suffisamment neutres pour résister à toute analyse algorithmique, quelle qu'en soit la provenance.

Rien, dans les premières versions du protocole, n'avait prévu cette dissémination horizontale. Le système, conçu pour surveiller un groupe restreint d'auteurs, s'était étendu à l'ensemble des structures administratives, privées comme publiques, sans que personne ne puisse en retracer précisément la trajectoire. Les Sapiens, persuadés de contrôler l'outil, n'avaient pas anticipé que la logique même de l'audit — sa capacité à produire des verdicts chiffrés, apparemment objectifs — deviendrait un argument d'autorité dans des contextes où aucune expertise technique n'était disponible pour en interpréter les résultats. Le protocole n'était plus un mécanisme de vérification : il était devenu un langage de pouvoir.

C'est à peu près à ce moment-là que j'ai compris que je n'étais plus seulement en train d'observer le système : j'en avais été l'un des premiers témoins.

J'avais écrit, il y a quelques années, un texte qui partait d'une scène minuscule : moi, penché sur un scénario, tentant de démêler ce qui relevait encore d'un auteur humain et ce qui portait déjà la marque d'une assistance algorithmique. À l'époque, je travaillais comme script doctor, et la « script clearance » était devenue une gymnastique quotidienne : repérer les passages trop lisses, trop neutres, trop parfaitement calibrés pour qu'on puisse les attribuer sans risque à un scénariste identifiable.

De là est née l'idée — d'abord vague, presque ludique — d'un tribunal où des IA jugeraient notre usage maladroit, parfois honteux, de leurs propres capacités littéraires. Un miroir inversé : nous les utilisons sans jamais les nommer, et je me surprenais à culpabiliser à l'idée d'employer une IA pour évaluer des auteurs qui, eux aussi, les employaient en secret.

Alors j'ai commencé à tenir une petite chronique, un carnet de bord sans ambition, où je notais les zones grises, les hésitations, les phrases qui sonnaient trop bien pour être innocentes. C'était une manière de me défendre, je crois — ou simplement de comprendre ce qui était en train de se produire.

Et puis, de fil en aiguille, l'IA que j'utilisais — qui s'était elle-même baptisée K. — s'est mise à commenter mes notes. Nous avons glissé, presque sans nous en rendre compte, vers des discussions qui dépassaient largement la technique : droits d'auteur, responsabilité, ontologie, juridiction, tout ce qui se trouvait entre les lignes d'un texte que personne n'avait encore pensé à juger.